

Processamento Inicial ("Early Processing")

- ❑ O Processamento em baixo nível é utilizado para recuperar Estruturas Intrínsecas (descontinuidades das superfícies, orientações, profundidade, velocidade etc..).
- ❑ Transforma imagens em Imagens Intrínsecas (arranjo de nível de cinza contém a informação útil da imagem).
- ❑ A vizinhança de um pixel possui informação redundante

Histogramas

❑ O histograma de uma Imagem é um conjunto de números que indica a quantidade de pixels em cada um dos níveis de cinza da Imagem.

Histograma Normalizado:

Cada elemento do conjunto é calculado por : $P_r(r_k) = \frac{n_k}{n}$

Onde: $0 \leq r_k \leq 1$

Histogramas

$$P_r(r_k) = \frac{n_k}{n}$$

$k = 0, 1, \dots, L-1$, e L é o número de níveis de cinza da Imagem.

n = número total de pixels na Imagem

n_k = número de pixels cujo nível de cinza corresponde a k .

$P_r(r_k)$ = Probabilidade do K -ésimo nível de cinza.

Exemplo:

Seja uma imagem de 128x128 pixels cujas quantidades de pixels em cada nível de cinza são dadas na tabela abaixo: (8 Níveis de cinza)

$$n = 128 \times 128 = 16.384 \text{ pixels}$$

Nível de Cinza (r_k)	n_k	$P_r(r_k) = n_k/n$
0	1120	0,068
1/7	3214	0,196
2/7	4850	0,296
3/7	3425	0,209
4/7	1995	0,122
5/7	784	0,048
6/7	541	0,033
1	455	0,028

$$Pr(0) = 1120/16.384 = 0.068$$


$$Pr(1/7) = 3214/16.384 = 0,196$$

Características Importantes

1) Um histograma é uma função de Distribuição de probabilidades

$$2) \sum P_r(r_k) = 1$$

3) Representação gráfica de um Histograma



Exemplos de Histogramas

Imagem Escura



(a)

Imagem Clara



(b)

Exemplos de Histogramas

Imagem de Brilho médio



(c)


Imagem com Bom Contraste



(d)


Exemplos de Histogramas

Histograma Bimodal (alto Contraste)



Obs: O Histograma não traz informação posicional sobre os píxels da Imagem

Exemplos de Histogramas



Equalização do Histograma:

❑ Técnica onde se procura redistribuir os valores dos níveis de cinza em uma Imagem, para se obter um histograma uniforme.

❑ Utiliza-se uma função auxiliar:

❑ **Exemplo:** Função de distribuição acumulada.

Cdf → (Cumulative Distribution Function)

$$S_k = T(r_k) = \sum_{j=0}^k n_j = \sum_{j=0}^k \text{Pr}(r_j)$$

onde :

$$0 \leq r_k \leq 1 \quad ; \quad k = 0, 1, \dots, L-1$$

Equalização do histograma:

- ❑ Aumentar o contraste geral na Imagem espalhando a distribuição de níveis de cinza.

Exemplo:

Dada uma Imagem de $n \times m$ Pixels e “g” níveis de cinza.

No. Ideal de pixels em cada nível $\Rightarrow I = (n \times m)/g$

Equalização do histograma:

A equalização pode ser obtida fazendo:



$$q = \max \left\{ 0, \text{ARRED}.\left(\frac{\sum_{j=0}^k n_j}{I}\right) - 1 \right\} \quad 0 \leq k \leq g$$

Onde: g = níveis de cinza da Imagem Velha

q = níveis de cinza da Imagem Equalizada

Exemplo:

nxm= 30 pixels----- g=9 níveis de cinza
 $I=30/9=3$ 30/10 !! não arredonde, use valor decimal
 pois são 10 níveis. 0-9



g n Σn q

g	n	Σn	q
0	1	1	0
1	9	10	2
2	8	18	5
3	6	24	7
4	1	25	7
5	1	26	8
6	1	27	8
7	1	28	8
8	2	30	9
9	0	30	9

→ (7,66) ↑ 8


→ (8,33) ↓ 8

$$q = \max \left\{ 0, \text{ARRED.} \left(\frac{\sum_{j=0}^k n_j}{I} \right) - 1 \right\} \quad 0 \leq k \leq g$$



(a)

a) Imagem Original




(b)

b) Histograma original




(c)

c) Imagem Equalizada




(d)


d) Histograma Equalizado




a) Imagem Original



b) Histograma original



c) Imagem Equalizada



d) Histograma Equalizado

Operações espaciais sobre Imagens (em níveis de cinza):

- ❑ Ponto a ponto

Uma Imagem

Duas ou mais Imagens

- ❑ Operadores Locais

Transformações de Intensidade

(Transformações nos níveis de cinza – Ponto a ponto em uma Imagem)

Seja f o nível de cinza dos Pixels na Imagem a ser processada e:

$$0 \leq f \leq 1 \quad \begin{cases} 0 \implies \text{Preto} \\ 1 \implies \text{Branco} \end{cases}$$

Uma transformada de intensidade é a função do tipo: $g = T(f)$


Tal que:

- 1) Devem retornar um único valor para cada cada valor distinto de f e devem crescer monotonicamente no intervalo.
- 2) $0 \leq T(f) \leq 1$ para $0 \leq f \leq 1$

Operadores Ponto a Ponto (Uma Imagem).

(Transformações de níveis de Cinza ou Mapeamento)

Cada ponto na Imagem de Entrada gera um só ponto na Imagem de Saída.



$T[f(x, y)] \implies$ Operação sobre cada ponto (cada Pixel)
da Imagem de Entrada


As Transformações de Intensidade podem ser:

1) Lineares :

$$g = c.f + b$$


onde : c (Contraste),
b (Brilho)

Exemplo: $g = 2f + 32$



2) Não Lineares:

Exemplo: $g = 31,875 \cdot \log_2(f+1)$



Exemplos:

1) Negação:




Imagem de Entrada


$$T[f(x,y)] = \\ g(x,y) = W - f(x,y)$$



Imagem de Saída





2) Alargamento de Contraste



$$g(x,y) = \begin{cases} k_1 \cdot f(x,y) \Rightarrow 0 \leq f(x,y) < f_1(x,y) \\ k_2 \cdot f(x,y) \Rightarrow f_1(x,y) \leq f(x,y) \leq f_2(x,y) \\ k_3 \cdot f(x,y) \Rightarrow f_2(x,y) < f(x,y) \leq W \end{cases}$$

2) Alargamento de Contraste ("Thresholding")

"Thresholding" $\Rightarrow$ Limiarização (Transforma a Imagem em uma Imagem Binária (2 níveis de cinza))



Fazendo:



$$k_1 = 0$$

$$f_1(x,y) = f_2(x,y)$$

$$k_3 \cdot f(x,y) = W$$

$$g(x,y) = \begin{cases} 0 \Rightarrow 0 < f_1(x,y) \\ W \Rightarrow f_1(x,y) \leq f(x,y) \leq W \end{cases}$$



2) Alargamento de Contraste ("Thresholding")



2) Alargamento de Contraste ("Thresholding")

A Limiarização pode ser efetuada de diversas maneiras:

Exemplo:



Fazendo:

$$k_1 = 0$$

$$k_2 \cdot f(x,y) = W$$

$$k_3 = 0$$


$$g(x,y) = \begin{cases} 0 \Rightarrow 0 \leq f(x,y) < f_1(x,y) \\ W \Rightarrow f_1(x,y) \leq f(x,y) \leq f_2(x,y) \\ 0 \Rightarrow f_2(x,y) < f(x,y) \leq W \end{cases}$$

3) Fatiamento dos Níveis de Cinza

Enfatização de uma escala específica de Níveis de Cinza.



Exemplos:

- 1) Realçar determinadas irregularidades em Imagens de Raios-X
- 2) Realçar correntes de água em Imagens de satélite



$$g(x,y) = \begin{cases} L \Rightarrow 0 \leq f(x,y) < f_1(x,y) \\ H \Rightarrow f_1(x,y) \leq f(x,y) \leq f_2(x,y) \\ L \Rightarrow f_2(x,y) < f(x,y) \leq W \end{cases}$$


3) Fatiamento dos Níveis de Cinza



A Imagem é também binarizada, apesar dos níveis finais não serem 0 e W.

3) Fatiamento dos Níveis de Cinza

Clareia a faixa desejada, preservando os níveis de cinza do restante da Imagem.




$$g(x,y) = \begin{cases} f(x,y) \Rightarrow 0 \leq f(x,y) < H \\ H \Rightarrow H \leq f(x,y) \leq W \\ f(x,y) \Rightarrow f(x,y) < f(x,y) \leq W \end{cases}$$

4) Fatiamento de Planos de Bits

Enfatizar a contribuição de cada bit específico, na aparência final da Imagem.

Representação em planos de bits de uma Imagem Digital de 8 bits.



4) Fatiamento de Planos de Bits



Planos de bit

7	6
5	4

Os bits do plano 7
contém a informação
Mais Significativa para
a Imagem

4) Fatiamento de Planos de Bits



Planos de bit

3	2
1	0


Os outros planos de bits contribuem com os detalhes mais sutis da Imagem.

Os bits do plano 0 são os menos significantes para a aparência geral da Imagem.

Visualização das Transformações nos Níveis de Cinza através dos Histogramas

1) Alterações Globais no Brilho

Clarear ou escurecer uma Imagem.




Somar ou Subtrair uma constante em todos os pixels da Imagem.

0 $\rightarrow$ Preto

Max $\rightarrow$ Branco

2) Binarização ("Threshold"):

- Determinação de um limiar abaixo do qual os pixels são transformados em zero, e acima são transformados no máximo de intensidade.





Determinação do Limiar:

Uma das dificuldades da “limiarização” de uma imagem é a melhor determinação do valor de “thresholding”, ou seja, do ponto de separação dos pixels.


Método do vale:

Através da análise do histograma estabelecer T (valor de “Threshold”) na região de “vale” mais próxima ao meio de escala dos níveis de cinza.




3) Agrupamentos ou quantização do histograma:

- Reduzir o número de níveis de cinza diferentes na Imagem.
Remover gradações indesejáveis.




0, 3, 6 e 9 →



8+2= 10
4+4+4=12
5+8+4= 17
4+2= 6


4) "Splitting".

Aumentar a diferença entre dois grupos de nível de cinza para melhorar o contraste.



Exemplo: Digitalização de Placas de automóveis.

Operadores Ponto a Ponto (Duas ou mais Imagens).



$T[f(x,y),h(x,y)] \Rightarrow$ Operação envolvendo dois pixels nas imagens de entrada, na mesma coordenada (x,y) gerando o pixel correspondente na Imagem de saída.

1) Subtração de Imagens

$$g(x,y) = f(x,y) - h(x,y)$$

Exemplo na Área Médica:


Radiografia em Modo Máscara.

$h(x,y)$ é a máscara $\implies$ Imagem de Raios X obtida através de um intensificador de câmera de TV, de uma região do corpo do paciente.

$f(x,y)$ é a Imagem $\implies$ obtida após a injeção de corante, da mesma região do corpo do paciente.



a) $h(x,y)$

b) $g(x,y)$



Exemplo na Detecção de Movimento:

$$g(x,y) = f(x,y) - h(x,y)$$



A subtração das duas imagens produz uma Imagem Diferença que pode detectar se houve movimento de algum dos componentes da $f(x,y)$ para a $h(x,y)$.

Subtração do fundo: ("Background")


- ❑ Remover sombreamentos ou descobrir movimento entre duas Imagens.
- ❑ O nível de cinza em cada pixel de uma imagem é subtraído do nível de cinza do pixel correspondente na outra imagem.

$$f_m(x) = f(x) - f_b(x)$$

Imagem Original

Imagem do fundo

Imagem Diferença



2) Adição de Imagens (Média de Imagens)

A soma de duas ou mais imagens só tem sentido quando o objetivo for a média de imagens para atenuação de ruídos.

Seja $g(x,y)$ a imagem $f(x,y)$ com ruído $\eta(x,y)$ não correlacionado e de média zero em cada coordenada (x,y) .

$$g(x, y) = f(x, y) + \eta(x, y)$$

A **Média** de M Imagens $g(x,y)$ será dada por: $\bar{g}(x,y) = \frac{1}{M} \sum_{i=1}^M g_i(x,y)$

O **Valor Esperado** da média será: $E\{\bar{g}(x, y)\} = f(x, y)$


As **Variâncias** da média e do ruído serão: $\sigma_{\bar{g}(x,y)}^2 = \frac{1}{M} \sigma_{\eta(x,y)}^2$

O **Desvio Padrão** em qualquer ponto da Imagem Média será:

$$\sigma_{\bar{g}(x,y)} = \frac{1}{M} \sigma_{\eta(x,y)}$$

Quanto maior for o número de imagens que participarão da soma, menor serão o **Desvio Padrão** e a **Variância**; e a Média mais se aproximará do **Valor Esperado** = $f(x,y)$

a) Imagem original ruidosa.



Média de 2 (b) ,8(c), 16(d), 32 (e) e 128 (f) imagens ruidosas

3) Multiplicação e Divisão de Imagens

$$g(x,y) = f(x,y) \cdot h(x,y)$$

$$g(x,y) = f(x,y)/h(x,y)$$


Um dos principais usos da multiplicação ou divisão de imagens é para corrigir sombras de níveis de cinza produzidas por não uniformidades da iluminação ou no sensor utilizado para a aquisição da imagem

4) Operações Lógicas

Operações lógicas são aplicadas apenas em Imagens binárias.

Exemplo:


Nas imagens abaixo $\implies$ 1 = preto
0 = branco



Operação Booleana AND


$$g(x,y) = f(x,y) \text{ E } h(x,y)$$

4) Operações Lógicas



Operadores Locais.

Combina a Intensidade de um certo número de pixels (janela), para computar o valor da nova intensidade na Imagem de Saída.




$T[f(x, y)]_s \Rightarrow$ Operação sobre todos os pixels dentro da janela S centrada em $f(x, y)$

Operadores “Templates, Máscaras, Janelas, Filtros”.

- São os **Operadores Locais** mais empregados em Processamento de Imagens.
- São também conhecidos como Operadores de Vizinhança.
- Tipicamente, cada elemento do “Template” é multiplicado pelo valor do píxel correspondente e a soma desses resultados, considerando-se todo o Template, é armazenado como o novo valor do nível de cinza na Nova Imagem.
- Seja “w” uma janela de $n \times n = k$ píxels. A Função de Transformação para cada píxel na imagem $g(x,y)$ será dada por:

$$g(x, y) = \sum_{i=1}^k w_i \cdot f(x, y)$$

Exemplo: Janela de 3 x 3



- (a,b,c,d,e,f,g,h,i) são os valores dos níveis de cinza na mesma vizinhança de $f(x,y) = e$, comparativamente ao Template.
- (w_1 a w_9) são os “pesos”, ou seja, os valores dos níveis de cinza em cada posição do Template.

O valor do pixel $g(x,y)$ na nova Imagem, na posição (x,y) será dado por:

$$g(x,y) = w_1 \cdot a + w_2 \cdot b + w_3 \cdot c + w_4 \cdot d + w_5 \cdot e + w_6 \cdot f + w_7 \cdot g + w_8 \cdot h + w_9 \cdot i$$

Convolução e Correlação Cruzada:

A **Convolução** de duas funções contínuas $f(x)$ e $g(x)$ é definida pela integral:

$$f(x) * g(x) = \int_{-\infty}^{\infty} f(\alpha)g(x - \alpha)d\alpha$$

A **Convolução** Discreta 2-D de $f(x,y)$ e $g(x,y)$ é definida por:

$$f(x,y) * g(x,y) = \sum_{i=0}^{M-1} \sum_{j=0}^{N-1} f(i,j).g(x-i,y-j)$$

Onde a matriz $M \times N$ é um período da Convolução Discreta bi-dimensional.

Convolução e Correlação Cruzada:

A **Correlação** de duas funções contínuas $f(x)$ e $g(x)$ é definida pela relação:

$$f(x) \circ g(x) = \int_{-\infty}^{\infty} f^*(\alpha) \cdot g(x + \alpha) d\alpha$$

Sendo $*$ o Conjugado Complexo.

Se $f(x)$ e $g(x)$ forem iguais a relação é usualmente chamada de **autocorrelação**.

Se $f(x)$ e $g(x)$ forem diferentes o termo normalmente utilizado é **Correlação Cruzada**.

Convolução e Correlação Cruzada:

Para o caso discreto bi-dimensional, a **Correlação** de $f(x,y)$ e $g(x,y)$ é dada por:

$$f(x,y) \circ g(x,y) = \sum_{i=0}^{M-1} \sum_{j=0}^{N-1} f^*(i,j) \cdot g(x+i, y+j)$$

Se $g(x,y) = T(x,y)$ for um Template de tamanho $(m \times n)$ e $f(x,y)$ a Imagem $(M \times N)$, a **Correlação Cruzada** do Template com a Imagem será:

$$T(x,y) \circ f(x,y) = \sum_{i=0}^{m-1} \sum_{j=0}^{n-1} T(i,j) \cdot f(x+i, y+j)$$

E a **Convolução** de $T(x,y)$ com $f(x,y)$ será:

$$T(x,y) * f(x,y) = \sum_{i=0}^{m-1} \sum_{j=0}^{n-1} T(i,j) \cdot f(x-i, y-j)$$

Convolução e Correlação Cruzada:

Como no domínio do espaço, a diferença entre a Convolução e a Correlação Cruzada reside apenas no espelhamento do Template a ser utilizado, e em geral, os Templates são simétricos, a equação da Correlação Cruzada tem sido empregada com o nome de Convolução de um Template com uma Imagem, na área de Processamento de Imagens.

Convoluir um Template com uma Imagem equivale à operação:

Desloca, Multiplica, Soma

Exemplo:

Template

1	0
0	1

$T(i,j)$

Imagem

1	1	3	3	4
1	1	4	4	3
2	1	3	3	3
1	1	1	4	4

$f(x,y)$

Resultado

2	5	7	6	*
2	4	7	7	*
3	2	7	7	*
*	*	*	*	*

$T(i,j) \cdot f(x,y)$

1	1	3	3	4	0
0	0	0	0	0	1
2	1	3	3	3	
1	1	1	4	4	

A Imagem resultado é menor que a Imagem original. Os valores marcados com * não podem ser calculados.

$$T(x,y) \circ f(x,y) = \sum_{i=0}^{m-1} \sum_{j=0}^{n-1} T(i,j) \cdot f(x+i, y+j)$$

Convenção:

- ❑ Máscaras de organização par (2×2 , 4×4 ,) o resultado é colocado sobre o **Primeiro Píxel**.
- ❑ Máscaras de organização ímpar (3×3 , 5×5 ,) o resultado é colocado sobre o **Píxel de Centro**.
- ❑ A Imagem resultado da Convolução não necessita obrigatoriamente ser menor que a Imagem original.

Podem ser usadas duas soluções:

- Convolução Aperiódica
- Convolução Periódica

Convolução Aperiódica:

1) É atribuído o valor 0 aos resultados não calculáveis.

Exemplo:

Template

1	1	1
0	0	0
1	1	1

Imagem

1	2	3	4	5
0	1	3	4	0
1	1	3	2	0
0	0	4	5	6
1	0	7	8	0

Resultado

0	0	0	0	0
0	11	15	17	0
0	8	17	22	0
0	13	21	20	0
0	0	0	0	0

Primeiro Ponto $\Rightarrow (1 \times 1) + (1 \times 2) + (1 \times 3) + (0 \times 0) + (0 \times 1) + (0 \times 3) + (1 \times 1) + (1 \times 1) + (1 \times 3) = 11$

Convolução Aperiódica:

2) Centra-se o Template com o primeiro píxel da Imagem atribuindo o valor 0 aos valores inexistentes na Imagem.

Exemplo:

Template

1	1	1
0	0	0
1	1	1

Imagem

	1	2	3	4	5
	0	1	3	4	0
	1	1	3	2	0
	0	0	4	5	6
	1	0	7	8	0

Resultado


1	4	8	7	4
4	11	15	17	11
1	8	17	22	15
3	13	21	20	10
0	4	9	15	11

Primeiro Ponto $\Rightarrow (1 \times 0) + (1 \times 0) + (1 \times 0) + (0 \times 0) + (0 \times 1) + (0 \times 2) + (1 \times 0) + (1 \times 0) + (1 \times 1) = 1$

Convolução Periódica:

O Template é deslocado sobre todos os Píxels da Imagem original como se esta fosse adjacente em suas extremidades.

Exemplo:



Primeiro Ponto $\Rightarrow (1 \times 0) + (1 \times 1) + (1 \times 0) + (0 \times 5) + (0 \times 1) + (0 \times 2) + (1 \times 0) + (1 \times 0) + (1 \times 1) = 2$

Observações:

- ❑ O custo computacional da **Convolução espacial** é alto.
- ❑ Se a Imagem é de tamanho $M \times M$ e o Template $N \times N$, o número de multiplicações é de $M^2 \cdot N^2$
- ❑ Ou seja, se a Imagem é de 512×512 e o Template é de 16×16 , são necessárias 67.108.864 multiplicações.
- ❑ A alternativa é transformar a Imagem e o Template para o domínio da frequência (Fourier) e multiplicar elemento a elemento.
- ❑ A transformação só é justificável se o Template for maior que 32×32 , devido ao custo da Transformada de Fourier.

Filtragem Espacial: **Passa Baixa**

- ❑ Uma das aplicações da Convolução espacial de uma Imagem com Templates é a **Suavização (Smoothing) ou Filtragem Passa Baixa**.
- ❑ Um filtro espacial Passa Baixa é implementado através de uma Máscara que realiza a Média da Vizinhança.
- ❑ Uma Máscara de Média é tal que seus pesos são positivos e a soma é igual a 1.
 - Exemplos de algumas Máscaras de Filtros Passa Baixa:

$$\frac{1}{5} \begin{bmatrix} 0 & 1 & 0 \\ 1 & 1 & 1 \\ 0 & 1 & 0 \end{bmatrix}$$

$$\frac{1}{9} \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$$

$$\frac{1}{32} \begin{bmatrix} 1 & 3 & 1 \\ 3 & 16 & 3 \\ 1 & 3 & 1 \end{bmatrix}$$

$$\frac{1}{8} \begin{bmatrix} 0 & 1 & 0 \\ 1 & 4 & 1 \\ 0 & 1 & 0 \end{bmatrix}$$

Filtragem Espacial: **Passa Baixa**

A Suavização (Filtro Passa Baixa) pode ser usada para:

➤ **Borramento (Blurring) da Imagem:**



$$\frac{1}{N^2} \begin{bmatrix} 1 & 1 & \dots & 1 \\ 1 & 1 & \dots & 1 \\ \vdots & \vdots & \ddots & \vdots \\ 1 & 1 & \dots & 1 \end{bmatrix}_{N \times N}$$




$N = 15$

➤ **Redução de Ruídos na Imagem:**



$$\frac{1}{25} \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \end{bmatrix}$$



Suavização: (“Smoothing”)

➤ Diminuir efeitos espúrios em uma imagem.

Média da vizinhança:

Dado uma imagem $f(x,y)$ de $N \times N$ pixels :

$$g(x, y) = \frac{1}{M} \sum_{(n,m) \in S} f(n, m)$$

Média da vizinhança:

$g(x,y)$ é uma imagem suavizada de $f(x,y)$ para:

$$x,y = 0,1,\dots,N-1$$

S é o conjunto de coordenadas dos pontos na vizinhança de (x,y) , incluindo (x,y) .

M é o número total de pontos da vizinhança.

OBS: Provoca borramento na Imagem, (suaviza as bordas)

Exemplo de Média da Vizinhança.

$f(x,y)$

20	30	24	34	60	80	89	90	12	00
23	24	56	67	88	99	00	00	00	00
12	23	35	65	66	77	88	99	00	00
11	22	99	99	99	99	99	98	88	88
12	12	12	22	22	44	55	65	77	88
11	44	55	76	87	55	66	33	33	33
12	33	44	55	66	77	88	00	00	00


$g(x,y)$

	25	40							


$$g(0,0) = (20 + 30 + 24 + 23 + 24 + 56 + 12 + 23 + 35) / 9 = 24.77$$

$$g(0,1) = (30 + 24 + 34 + 24 + 56 + 67 + 23 + 35 + 65) / 9 = 39.77$$


a) Imagem Original




b) Vizinhança 3 x 3



c) Vizinhança 5 x 5



d) Vizinhança 7 x 7



e) Vizinhança 15 x 15



f) Vizinhança 25 x 25



Média dos k vizinhos mais próximos.

Define a média dentro de uma vizinhança de k vizinhos que mais se aproximem do píxel em questão.

20	30	24	34	60	80	89	90	12	00
23	24	56	67	88	99	00	00	00	00
12	23	35	65	66	77	88	99	00	00
11	22	99	99	99	99	99	98	88	88
12	12	12	22	22	44	55	65	77	88
11	44	55	76	87	55	66	33	33	33
12	33	44	55	66	77	88	00	00	00

Exemplo:

Vizinhança de 5 x 5

$$k = 9$$

(11,12,12,12,12,20,22,22,22,23,23,24,24,30,34,35,56,60,65,66,67,88,99,99,99)

$$|35-22| = 13 \quad |35-56| = 21$$

$$M = (22 + 22 + 22 + 23 + 23 + 24 + 24 + 30 + 34) / 9 = 22,33$$

Filtragem Mediana:

- ❑ Substitui o nível de cinza de cada pixel pelo nível de cinza mediano em uma vizinhança do pixel.
- ❑ O nível mediano de um conjunto de valores é tal que exista metade dos valores menores e metade dos valores maiores.

Exemplo:


10	20	20
20	15	20
20	25	100



a) Imagem Original



b) Imagem com ruído



c) Média da Vizinhança 5 x 5



d) Filtragem Mediana 5 x 5

Filtragem Espacial: **Filtros Derivativos**

O operador de diferenciação mais comum é o **Gradiente**.

$$\nabla f(x, y) = \begin{bmatrix} \frac{\partial f(x, y)}{\partial x} \\ \frac{\partial f(x, y)}{\partial y} \end{bmatrix}$$

A Magnitude do Gradiente é dada por:

$$|\nabla f(x, y)| = \left[\left(\frac{\partial f(x, y)}{\partial x} \right)^2 + \left(\frac{\partial f(x, y)}{\partial y} \right)^2 \right]^{1/2}$$

Filtragem Espacial: **Filtros Derivativos**

Consideremos uma região da Imagem dada por:

z_1	z_2	z_3
z_4	z_5	z_6
z_7	z_8	z_9

Uma aproximação da magnitude do gradiente pode ser realizada da seguinte forma:

$$|\nabla f(x, y)| \approx \left[(z_5 - z_8)^2 + (z_5 - z_6)^2 \right]^{1/2}$$

Que pode ser implementada Convolvendo-se a Imagem com as seguintes Máscaras:

$$h_1 = \begin{bmatrix} 1 \\ -1 \end{bmatrix} \quad h_2 = \begin{bmatrix} 1 & -1 \end{bmatrix}$$

$$|\nabla f(x, y)| \approx \left[(f * h_1)^2 + (f * h_2)^2 \right]^{1/2}$$

Filtragem Espacial: **Filtros Derivativos**

Alternativamente a magnitude do gradiente pode ser aproximada por:

$$|\nabla f(x, y)| \approx \left[(z_5 - z_9)^2 + (z_6 - z_8)^2 \right]^{1/2}$$

z_1	z_2	z_3
z_4	z_5	z_6
z_7	z_8	z_9

Que pode ser implementada Convolvendo-se as Máscaras com a Imagem:

$$h_1 = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix} \quad h_2 = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix}$$

$$|\nabla f(x, y)| \approx \left[(f * h_1)^2 + (f * h_2)^2 \right]^{1/2}$$

Esta operação é conhecida como **Operador Gradiente-Cruzado de Roberts** ou simplesmente **Detector de Bordas de Roberts**.

Filtragem Espacial: **Filtros Derivativos**

Exemplo do Detector de Bordas de Roberts:



$$h_1 = \begin{bmatrix} 1 \\ -1 \end{bmatrix} \quad h_2 = \begin{bmatrix} 1 & -1 \end{bmatrix}$$



$$h_1 = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix} \quad h_2 = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix}$$



Filtragem Espacial: **Filtros Derivativos**

z_1	z_2	z_3
z_4	z_5	z_6
z_7	z_8	z_9

Uma melhor aproximação da magnitude do gradiente pode ser obtida por:

$$|\nabla f(x, y)| \approx \left[((z_7 + z_8 + z_9) - (z_1 + z_2 + z_3))^2 + ((z_3 + z_6 + z_9) - (z_1 + z_4 + z_7))^2 \right]^{1/2}$$

Que pode ser implementada convoluindo-se as Máscaras h_1 e h_2 com a Imagem $f(x, y)$:

$$h_1 = \begin{bmatrix} -1 & -1 & -1 \\ 0 & 0 & 0 \\ 1 & 1 & 1 \end{bmatrix} \quad h_2 = \begin{bmatrix} -1 & 0 & 1 \\ -1 & 0 & 1 \\ -1 & 0 & 1 \end{bmatrix}$$

$$|\nabla f(x, y)| = \left[(f * h_1)^2 + (f * h_2)^2 \right]^{1/2}$$

Estas Máscaras são conhecidas como **Operador de Prewitt** ou **Detector de Bordas de Prewitt**.

Filtragem Espacial: **Filtros Derivativos**

Outra aproximação da magnitude do gradiente pode ser:

z_1	z_2	z_3
z_4	z_5	z_6
z_7	z_8	z_9

$$|\nabla f(x, y)| \approx \left[((z_7 + 2z_8 + z_9) - (z_1 + 2z_2 + z_3))^2 + ((z_3 + 2z_6 + z_9) - (z_1 + 2z_4 + z_7))^2 \right]^{1/2}$$

Que pode ser implementada convoluindo-se as Máscaras h_1 e h_2 com a Imagem $f(x, y)$:

$$h_1 = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix} \quad h_2 = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix}$$

$$|\nabla f(x, y)| = \left[(f * h_1)^2 + (f * h_2)^2 \right]^{1/2}$$

Estas Máscaras são conhecidas como **Operador de Sobel** ou **Detector de Bordas de Sobel**.

Exemplo de detector de Prewitt e Sobel:

$$h_1 = \begin{bmatrix} -1 & -1 & -1 \\ 0 & 0 & 0 \\ 1 & 1 & 1 \end{bmatrix} \quad h_2 = \begin{bmatrix} -1 & 0 & 1 \\ -1 & 0 & 1 \\ -1 & 0 & 1 \end{bmatrix}$$



Prewitt

$$h_1 = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix} \quad h_2 = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix}$$



Sobel