


Operadores Locais.

Combina a Intensidade de um certo número de pixels (janela), para computar o valor da nova intensidade na Imagem de Saída.




$T[f(x, y)]_S \Rightarrow$ Operação sobre todos os pixels dentro da janela S centrada em $f(x, y)$

Operadores “Templates, Máscaras, Janelas, Filtros”.

- São os **Operadores Locais** mais empregados em Processamento de Imagens.
- São também conhecidos como Operadores de Vizinhança.
- Tipicamente, cada elemento do “Template” é multiplicado pelo valor do píxel correspondente e a soma desses resultados, considerando-se todo o Template, é armazenado como o novo valor do nível de cinza na Nova Imagem.
- Seja “w” uma janela de $n \times n = k$ píxels. A Função de Transformação para cada píxel na imagem $g(x,y)$ será dada por:

$$g(x, y) = \sum_{i=1}^k w_i \cdot f(x, y)$$

Exemplo: Janela de 3 x 3



- (a,b,c,d,e,f,g,h,i) são os valores dos níveis de cinza na mesma vizinhança de $f(x,y) = e$, comparativamente ao Template.
- (w_1 a w_9) são os “pesos”, ou seja, os valores dos níveis de cinza em cada posição do Template.

O valor do pixel $g(x,y)$ na nova Imagem, na posição (x,y) será dado por:

$$g(x,y) = w_1 \cdot a + w_2 \cdot b + w_3 \cdot c + w_4 \cdot d + w_5 \cdot e + w_6 \cdot f + w_7 \cdot g + w_8 \cdot h + w_9 \cdot i$$

Convolução e Correlação Cruzada:

A **Convolução** de duas funções contínuas $f(x)$ e $g(x)$ é definida pela integral:

$$f(x) * g(x) = \int_{-\infty}^{\infty} f(\alpha) g(x - \alpha) d\alpha$$

A **Convolução** Discreta 2-D de $f(x,y)$ e $g(x,y)$ é definida por:

$$f(x,y) * g(x,y) = \sum_{i=0}^{M-1} \sum_{j=0}^{N-1} f(i,j) \cdot g(x-i, y-j)$$

Onde a matriz $M \times N$ é um período da Convolução Discreta bi-dimensional.

Convolução e Correlação Cruzada:

A **Correlação** de duas funções contínuas $f(x)$ e $g(x)$ é definida pela relação:

$$f(x) \circ g(x) = \int_{-\infty}^{\infty} f^*(\alpha) \cdot g(x + \alpha) d\alpha$$

Sendo $*$ o Conjugado Complexo.

Se $f(x)$ e $g(x)$ forem iguais a relação é usualmente chamada de **autocorrelação**.

Se $f(x)$ e $g(x)$ forem diferentes o termo normalmente utilizado é **Correlação Cruzada**.

Convolução e Correlação Cruzada:

Para o caso discreto bi-dimensional, a **Correlação** de $f(x,y)$ e $g(x,y)$ é dada por:

$$f(x,y) \circ g(x,y) = \sum_{i=0}^{M-1} \sum_{j=0}^{N-1} f^*(i,j) \cdot g(x+i, y+j)$$

Se $g(x,y) = T(x,y)$ for um Template de tamanho $(m \times n)$ e $f(x,y)$ a Imagem $(M \times N)$, a **Correlação Cruzada** do Template com a Imagem será:

$$T(x,y) \circ f(x,y) = \sum_{i=0}^{m-1} \sum_{j=0}^{n-1} T(i,j) \cdot f(x+i, y+j)$$

E a **Convolução** de $T(x,y)$ com $f(x,y)$ será:

$$T(x,y) * f(x,y) = \sum_{i=0}^{m-1} \sum_{j=0}^{n-1} T(i,j) \cdot f(x-i, y-j)$$

Convolução e Correlação Cruzada:

Como no domínio do espaço, a diferença entre a Convolução e a Correlação Cruzada reside apenas no espelhamento do Template a ser utilizado, e em geral, os Templates são simétricos, a equação da Correlação Cruzada tem sido empregada com o nome de Convolução de um Template com uma Imagem, na área de Processamento de Imagens.

Convoluir um Template com uma Imagem equivale à operação:

Desloca, Multiplica, Soma

Exemplo:

Template

1	0
0	1

$T(i,j)$

Imagem

1	1	3	3	4
1	1	4	4	3
2	1	3	3	3
1	1	1	4	4

$f(x,y)$

Resultado

2	5	7	6	*
2	4	7	7	*
3	2	7	7	*
*	*	*	*	*

$T(i,j)*f(x,y)$

1	1	3	3	4	0
0	0	0	0	0	1
2	1	3	3	3	
1	1	1	4	4	

A Imagem resultado é menor que a Imagem original. Os valores marcados com * não podem ser calculados.

$$T(x,y) \circ f(x,y) = \sum_{i=0}^{m-1} \sum_{j=0}^{n-1} T(i,j) \cdot f(x+i, y+j)$$

Convenção:

- ❑ Máscaras de organização par (2×2 , 4×4 ,) o resultado é colocado sobre o **Primeiro Píxel**.
- ❑ Máscaras de organização ímpar (3×3 , 5×5 ,) o resultado é colocado sobre o **Píxel de Centro**.
- ❑ A Imagem resultado da Convolução não necessita obrigatoriamente ser menor que a Imagem original.

Podem ser usadas duas soluções:

- Convolução Aperiódica
- Convolução Periódica

Convolução Aperiódica:

1) É atribuído o valor 0 aos resultados não calculáveis.

Exemplo:

Template

1	1	1
0	0	0
1	1	1

Imagem

1	2	3	4	5
0	1	3	4	0
1	1	3	2	0
0	0	4	5	6
1	0	7	8	0

Resultado

0	0	0	0	0
0	11	15	17	0
0	8	17	22	0
0	13	21	20	0
0	0	0	0	0

Primeiro Ponto $\Rightarrow (1 \times 1) + (1 \times 2) + (1 \times 3) + (0 \times 0) + (0 \times 1) + (0 \times 3) + (1 \times 1) + (1 \times 1) + (1 \times 3) = 11$

Convolução Aperiódica:

2) Centra-se o Template com o primeiro píxel da Imagem atribuindo o valor 0 aos valores inexistentes na Imagem.

Exemplo:

Template

1	1	1
0	0	0
1	1	1

Imagem

	1	2	3	4	5
	0	1	3	4	0
	1	1	3	2	0
	0	0	4	5	6
	1	0	7	8	0

Resultado

1	4	8	7	4
4	11	15	17	11
1	8	17	22	15
3	13	21	20	10
0	4	9	15	11

Primeiro Ponto ==> $(1 \times 0) + (1 \times 0) + (1 \times 0) + (0 \times 0) + (0 \times 1) + (0 \times 2) + (1 \times 0) + (1 \times 0) + (1 \times 1) = 1$

Convolução Periódica:

O Template é deslocado sobre todos os Píxels da Imagem original como se esta fosse adjacente em suas extremidades.

Exemplo:

Template

1	1	1
0	0	0
1	1	1

Imagem

Imagem

	1	2	3	4	5
	0	1	3	4	0
	1	1	3	2	0
	0	0	4	5	6
	1	0	7	8	0

Resultado

2	12	23	22	13
10	11	15	17	13
7	8	17	22	15
3	13	21	20	12
14	10	18	27	21

Primeiro Ponto $\Rightarrow (1 \times 0) + (1 \times 1) + (1 \times 0) + (0 \times 5) + (0 \times 1) + (0 \times 2) + (1 \times 0) + (1 \times 0) + (1 \times 1) = 2$

Observações:

- ❑ O custo computacional da **Convolução espacial** é alto.
- ❑ Se a Imagem é de tamanho $M \times M$ e o Template $N \times N$, o número de multiplicações é de $M^2 \cdot N^2$
- ❑ Ou seja, se a Imagem é de 512×512 e o Template é de 16×16 , são necessárias 67.108.864 multiplicações.
- ❑ A alternativa é transformar a Imagem e o Template para o domínio da frequência (Fourier) e multiplicar elemento a elemento.
- ❑ A transformação só é justificável se o Template for maior que 32×32 , devido ao custo da Transformada de Fourier.

Filtragem Espacial: **Passa Baixa**

- ❑ Uma das aplicações da Convolução espacial de uma Imagem com Templates é a **Suavização (Smoothing) ou Filtragem Passa Baixa**.
- ❑ Um filtro espacial Passa Baixa é implementado através de uma Máscara que realiza a Média da Vizinhança.
- ❑ Uma Máscara de Média é tal que seus pesos são positivos e a soma é igual a 1.
 - Exemplos de algumas Máscaras de Filtros Passa Baixa:

$$\frac{1}{5} \begin{bmatrix} 0 & 1 & 0 \\ 1 & 1 & 1 \\ 0 & 1 & 0 \end{bmatrix}$$

$$\frac{1}{9} \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$$

$$\frac{1}{32} \begin{bmatrix} 1 & 3 & 1 \\ 3 & 16 & 3 \\ 1 & 3 & 1 \end{bmatrix}$$

$$\frac{1}{8} \begin{bmatrix} 0 & 1 & 0 \\ 1 & 4 & 1 \\ 0 & 1 & 0 \end{bmatrix}$$

Filtragem Espacial: **Passa Baixa**

A Suavização (Filtro Passa Baixa) pode ser usada para:

➤ **Borramento (Blurring) da Imagem:**



$$\frac{1}{N^2} \begin{bmatrix} 1 & 1 & \dots & 1 \\ 1 & 1 & \dots & 1 \\ \vdots & \vdots & \ddots & \vdots \\ 1 & 1 & \dots & 1 \end{bmatrix}_{N \times N}$$



$N = 15$

➤ **Redução de Ruídos na Imagem:**



$$\frac{1}{25} \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \end{bmatrix}$$



Suavização: (“Smoothing”)

➤ Diminuir efeitos espúrios em uma imagem.

Média da vizinhança:

Dado uma imagem $f(x,y)$ de $N \times N$ pixels :

$$g(x, y) = \frac{1}{M} \sum_{(n,m) \in S} f(n, m)$$

Média da vizinhança:

$g(x,y)$ é uma imagem suavizada de $f(x,y)$ para:

$$x,y = 0,1,\dots,N-1$$

S é o conjunto de coordenadas dos pontos na vizinhança de (x,y) , incluindo (x,y) .

M é o número total de pontos da vizinhança.

OBS: Provoca borramento na Imagem, (suaviza as bordas)

Exemplo de Média da Vizinhança.

$f(x,y)$

20	30	24	34	60	80	89	90	12	00
23	24	56	67	88	99	00	00	00	00
12	23	35	65	66	77	88	99	00	00
11	22	99	99	99	99	99	98	88	88
12	12	12	22	22	44	55	65	77	88
11	44	55	76	87	55	66	33	33	33
12	33	44	55	66	77	88	00	00	00

$g(x,y)$

	25	40							


$$g(0,0) = (20 + 30 + 24 + 23 + 24 + 56 + 12 + 23 + 35) / 9 = 24.77$$

$$g(0,1) = (30 + 24 + 34 + 24 + 56 + 67 + 23 + 35 + 65) / 9 = 39.77$$


a) Imagem Original




b) Vizinhança 3 x 3



c) Vizinhança 5 x 5




d) Vizinhança 7 x 7



e) Vizinhança 15 x 15



f) Vizinhança 25 x 25



Média dos k vizinhos mais próximos.

Define a média dentro de uma vizinhança de k vizinhos que mais se aproximem do píxel em questão.

20	30	24	34	60	80	89	90	12	00
23	24	56	67	88	99	00	00	00	00
12	23	35	65	66	77	88	99	00	00
11	22	99	99	99	99	99	98	88	88
12	12	12	22	22	44	55	65	77	88
11	44	55	76	87	55	66	33	33	33
12	33	44	55	66	77	88	00	00	00

Exemplo:

Vizinhança de 5 x 5

$$k = 9$$

(11,12,12,12,12,20,22,22,22,23,23,24,24,30,34,35,56,60,65,66,67,88,99,99,99)

$$|35-22| = 13 \quad |35-56| = 21$$

$$M = (22 + 22 + 22 + 23 + 23 + 24 + 24 + 30 + 34) / 9 = 22,33$$

Filtragem Mediana:

- ❑ Substitui o nível de cinza de cada pixel pelo nível de cinza mediano em uma vizinhança do pixel.
- ❑ O nível mediano de um conjunto de valores é tal que exista metade dos valores menores e metade dos valores maiores.

Exemplo:

10	20	20
20	15	20
20	25	100



a) Imagem Original



b) Imagem com ruído



c) Média da Vizinhança 5 x 5



d) Filtragem Mediana 5 x 5

Filtragem Espacial: **Filtros Derivativos**

O operador de diferenciação mais comum é o **Gradiente**.

$$\nabla f(x, y) = \begin{bmatrix} \frac{\partial f(x, y)}{\partial x} \\ \frac{\partial f(x, y)}{\partial y} \end{bmatrix}$$

A Magnitude do Gradiente é dada por:

$$|\nabla f(x, y)| = \left[\left(\frac{\partial f(x, y)}{\partial x} \right)^2 + \left(\frac{\partial f(x, y)}{\partial y} \right)^2 \right]^{1/2}$$

Filtragem Espacial: **Filtros Derivativos**

Consideremos uma região da Imagem dada por:

z_1	z_2	z_3
z_4	z_5	z_6
z_7	z_8	z_9

Uma aproximação da magnitude do gradiente pode ser realizada da seguinte forma:

$$|\nabla f(x, y)| \approx \left[(z_5 - z_8)^2 + (z_5 - z_6)^2 \right]^{1/2}$$

Que pode ser implementada Convolvendo-se a Imagem com as seguintes Máscaras:

$$h_1 = \begin{bmatrix} 1 \\ -1 \end{bmatrix} \quad h_2 = \begin{bmatrix} 1 & -1 \end{bmatrix}$$

$$|\nabla f(x, y)| \approx \left[(f * h_1)^2 + (f * h_2)^2 \right]^{1/2}$$

Filtragem Espacial: Filtros Derivativos

Alternativamente a magnitude do gradiente pode ser aproximada por:

$$|\nabla f(x, y)| \approx \left[(z_3 - z_9)^2 + (z_6 - z_8)^2 \right]^{1/2}$$

z_1	z_2	z_3
z_4	z_5	z_6
z_7	z_8	z_9

Que pode ser implementada Convolvendo-se as Máscaras com a Imagem:

$$h_1 = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix} \quad h_2 = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix}$$

$$|\nabla f(x, y)| \approx \left[(f * h_1)^2 + (f * h_2)^2 \right]^{1/2}$$

Esta operação é conhecida como **Operador Gradiente-Cruzado de Roberts** ou simplesmente **Detector de Bordas de Roberts**.

Filtragem Espacial: **Filtros Derivativos**

Exemplo do Detector de Bordas de Roberts:



$$h_1 = \begin{bmatrix} 1 \\ -1 \end{bmatrix} \quad h_2 = \begin{bmatrix} 1 & -1 \end{bmatrix}$$



$$h_1 = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix} \quad h_2 = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix}$$



Filtragem Espacial: Filtros Derivativos

Uma melhor aproximação da magnitude do gradiente pode ser obtida por:

z_1	z_2	z_3
z_4	z_5	z_6
z_7	z_8	z_9

$$|\nabla f(x, y)| \approx \left[((z_7 + z_8 + z_9) - (z_1 + z_2 + z_3))^2 + ((z_3 + z_6 + z_9) - (z_1 + z_4 + z_7))^2 \right]^{1/2}$$

Que pode ser implementada convoluindo-se as Máscaras h_1 e h_2 com a Imagem $f(x, y)$:

$$h_1 = \begin{bmatrix} -1 & -1 & -1 \\ 0 & 0 & 0 \\ 1 & 1 & 1 \end{bmatrix} \quad h_2 = \begin{bmatrix} -1 & 0 & 1 \\ -1 & 0 & 1 \\ -1 & 0 & 1 \end{bmatrix}$$

$$|\nabla f(x, y)| = \left[(f * h_1)^2 + (f * h_2)^2 \right]^{1/2}$$

Estas Máscaras são conhecidas como **Operador de Prewitt** ou **Detector de Bordas de Prewitt**.

Filtragem Espacial: Filtros Derivativos

Outra aproximação da magnitude do gradiente pode ser:

z_1	z_2	z_3
z_4	z_5	z_6
z_7	z_8	z_9

$$|\nabla f(x, y)| \approx \left[((z_7 + 2z_8 + z_9) - (z_1 + 2z_2 + z_3))^2 + ((z_3 + 2z_6 + z_9) - (z_1 + 2z_4 + z_7))^2 \right]^{1/2}$$

Que pode ser implementada convoluindo-se as Máscaras h_1 e h_2 com a Imagem $f(x, y)$:


$$h_1 = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix} \quad h_2 = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix}$$

$$|\nabla f(x, y)| = \left[(f * h_1)^2 + (f * h_2)^2 \right]^{1/2}$$

Estas Máscaras são conhecidas como **Operador de Sobel** ou **Detector de Bordas de Sobel**.

Exemplo de detector de Prewitt e Sobel:

$$h_1 = \begin{bmatrix} -1 & -1 & -1 \\ 0 & 0 & 0 \\ 1 & 1 & 1 \end{bmatrix} \quad h_2 = \begin{bmatrix} -1 & 0 & 1 \\ -1 & 0 & 1 \\ -1 & 0 & 1 \end{bmatrix}$$



Prewitt

$$h_1 = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix} \quad h_2 = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix}$$



Sobel