



Fundamentos

Introdução



- Uma das primeiras aplicações de técnicas de PDI para interpretação humana: imagens digitalizadas para jornal
- Transmitidas por cabos submarinos entre Londres e Nova York
- Desenvolvida no início do século 20

Introdução



- O tempo de transporte caiu de uma semana para menos de 3hs.
- Problemas iniciais: procedimentos de impressão e distribuição dos níveis de cinza (a reprodução das imagens era feita em uma impressora de télégrafo simulando *halftone*)

Introdução



FIGURE 1.1 A digital picture produced in 1921 from a coded tape by a telegraph printer with special type faces. (McFarlane.[†])



FIGURE 1.2 A digital picture made in 1922 from a tape punched after the signals had crossed the Atlantic twice. (McFarlane.)

Uma imagem digital produzida em 1921 de uma fita codificada usando impressora telegráfica com tipos especiais

Uma imagem digital feita em 1922 de uma fita perfurada após os sinais terem cruzado o Atlântico duas vezes

Introdução



FIGURE 1.3
Unretouched
cable picture of
Generals Pershing
and Foch,
transmitted in
1929 from
London to New
York by 15-tone
equipment.
(McFarlane.)

Imagem sem retoques dos
generais Pershing e Foch,
transmitidos em 1929 de
Londres a Nova York por
um equipamento de 15
níveis de cinza

Introdução



FIGURE 1.4 The first picture of the moon by a U.S. spacecraft. *Ranger 7* took this image on July 31, 1964 at 9 : 09 A.M. EDT, about 17 minutes before impacting the lunar surface. (Courtesy of NASA.)

Primeira imagem
da Lua por uma nave
espacial americana.
Ranger 7 captou essa
imagem em 31/07/1964
aproximadamente 17 min.
antes do impacto com a
superfície lunar.

Introdução



- Os primeiros computadores poderosos o suficiente para realizar tarefas de proc. de imagens significativas foram desenvolvidos no início da década 60
- Primeira imagem tirada da Lua por uma espaçonave.
- Serviram como base para métodos avançados de realce e restauração imagens para outras missões

Introdução



- Imagens podem ser **capturadas** por uma variedade de **sensores**.
- O processamento delas possibilita diversas aplicações
 - Transmissão de vídeo,
 - diagnóstico médico,
 - controle de qualidade de processos industriais,
 - vigilância, etc.

Introdução



- Imagens científicas



Introdução



- Imagens científicas



- Transmissão
- Compressão
- Aplicações
 - Câmeras digitais
 - Web
 - Videos

Introdução (cont)



- Edição de vídeos e imagens



Introdução (cont)





Stalin e Nikolai Yezhov



Nikolai Yezhov removido

Introdução (cont)



“Cornelia, Mother of the Gracchi” by J. Sucee (Louvre). Emile-Male “The Restorer’s Handbook of easel painting

Introdução (cont)



Introdução (cont)



Introdução (cont)




Introdução (cont)




Introdução (cont)



Introdução (cont)



Introdução (cont)



Análise Estrutural
da Rocha




Visão Noturna



Segurança de
Ambientes



Escritório e Lazer



Metalurgia



Imagens Médicas



Reconhecimento de
Digitais



Previsão
Meteorológica

Introdução (cont)



Controle de Qualidade



Controle de Processo Industrial



Rastreabilidade



Controle de Tráfego



Inspeção de Áreas Geográficas



Astronomia

O que é processamento de imagens?



- Significa modificar as informações contidas na imagem sob vários aspectos.
- O resultado pode ser uma imagem ou um conjunto de informações extraídas





O que é processamento de imagens?



- Consiste em um conjunto de técnicas para **capturar, representar e transformar** imagens com o auxílio do computador
- O emprego dessas técnicas permite:
 - **extrair e identificar** informações das imagens
 - **melhorar a qualidade** visual
 - **facilita a percepção** humana e a **interpretação automática**

O que é processamento de imagens?



Captura da imagem

O que é processamento de imagens?



Transf.



O que é processamento de imagens?




Transf.




O que é processamento de imagens?



Representar



Computação visual



Computação visual (cont.)



- Processamento de Imagens
 - Entrada: imagem;
 - Saída: imagem
- Síntese de imagens
 - Entrada: representação 3D;
 - Saída: imagem
- Análise de Imagens
 - Entrada: imagem;
 - Saída: forma e outras características 3D
 - Exemplos: Visão Computacional, Reconhecimento de padrões

Síntese de Imagens



- Criação de imagens por computador.
- Ocupa-se da **produção de representações visuais** a partir das **especificações geométricas e visuais** de seus componentes;
- É uma das sub-áreas mais difundidas e geralmente confundida com a própria computação gráfica
- Área de CAD usa síntese de imagens

Síntese de Imagens



Exemplos

- Simulações espaciais
- Jogos
- Maquetes





Análise de Imagens



- Interpretação de informações da imagem através de algoritmos computacionais.
- Tomam imagens como entradas, mas produzem outros tipos de saída.
- Obtém parâmetros descritivos da imagem.
- Usada para a realização de **Reconhecimento de Padrões, Visão Computacional** ou de extração de conhecimento das imagens (**Mineração de Imagens**).

Análise de Imagens



Processamento de Imagens



- Dados **de entrada e saída** são **imagens**
- Manipulação dos pontos ou *pixels* (*picture element*) da imagem.
- As transformações visam, em geral, **melhorar as características visuais** da imagem, como aumentar o contraste, foco, reduzir ruídos e distorções.

Processamento de Imagens



Imagem original





Imagem suavizada



Bordas da Imagem

Relação entra as áreas




Visão Computacional



- Um conjunto de técnicas computacionais para **estimar** ou explicitar as **propriedades geométricas e dinâmicas do mundo 3D** a partir de **imagens digitais**
- Sistema de Visão Computacional
 - Hardware de aquisição (adquire e armazena imagens num computador)
 - Processamento de imagens
 - Mostrar os resultados aos usuários ou a outros sistemas computacionais

Visão Computacional



Reconhecimento de Padrões



- Técnicas para reconhecer e classificar objetos usando imagens digitais
- Classificar informações (padrões) baseado em conhecimento *a priori* ou em informações estatísticas extraídas dos padrões.

Mineração de Imagens



- **Extracção de conhecimento**, da relação dos dados de uma imagem, ou outros padrões não armazenados explicitamente nas imagens.
- Vai mais além de ser uma extensão de mineração de dados.

Mineração de Imagens



- É um **esforço multidisciplinar** que se baseia nas qualidades:
 - visão computacional,
 - processamento de imagens,
 - recuperação de imagens,
 - mineração de dados,
 - aprendizado de máquina,
 - banco de dados e
 - inteligencia artificial.

Resumo



Dados Geométricos 3D



Computação Gráfica

Imagem 2D



Imagem 2D



Processamento de
imagens

Imagem 2D



Imagem 2D




Visão Computacional


Dados Geométricos 3D





Pipeline convencional



Espectro Eletromagnético






Exemplos de imagens



Exemplos de imagens de raios-
gamma

1. “escaneamento” do esqueleto
2. Imagem PET (Positron Emission Tomography)
3. Constelação de Cygnus
4. Radiação gamma (mancha brilhante) de uma válvula de reator


Exemplos de imagens (cont.)



Exemplos de imagens
de raios-X:


1. do tórax,
2. angiograma aórtica,
3. CT (computed tomography)
da cabeça,
4. circuitos eletrônicos, e
5. constelação de Cygnus.

Exemplos de imagens (cont.)




Exemplos de imagens ultravioleta:

1. milho normal,
2. milho infectado, e
3. constelação de Cygnus.



Exemplos de imagens (cont.)



Exemplo de imagens microscópicas


1. Taxol (agente anticancer) 250x
2. Cholesterol 40x
3. Microprocessador 60x
4. filme de óxido de níquel 600x
5. superfície de um CD de áudio 1750x
6. supercondutor orgânico 450x

Exemplos de imagens (cont.)




Imagens acústicas (ultrassom)

1. feto
2. outra vista do feto
3. tiróide
4. camada muscular com uma lesão



signatures of magnetic fields permeating the galactic plane, which includes regions of intense star formation and the remnants of dramatic supernova explosions.

Exemplos de imagens (cont.)



- Imagens de satélite do furacão Katrina captadas em 29 de agosto de 2005.
- Microondas

Lidar (TOF)



Fundamentação

- Um modelo simples de imagem

- Uma função de intensidade luminosa bidimensional $f(x, y)$

$$f(x, y) = i(x, y) r(x, y)$$


$i(x, y)$: componente de iluminação, $0 < i(x, y) < \infty$


$r(x, y)$: componente de reflectância, $0 < r(x, y) < 1$

Na teoria : $0 < f(x, y) < \infty$

Na prática : $L_{\min} < f(x, y) < L_{\max}$


- Digitalização da imagem





Amostragem: $f(x,y)$ é amostrada em pontos discretos (pixels)

Quantização: $[L_{min}, L_{max}] = [0, 255] \Rightarrow G = 256$
onde, G é o número de níveis de cinza



- Imagem Digital

$$f(x, y) = \begin{bmatrix} f(0,0) & f(0,1) & \dots & f(0,M-1) \\ f(1,0) & f(1,1) & & \vdots \\ \vdots & & & \\ f(N-1,0) & \dots & \dots & f(N-1,M-1) \end{bmatrix}$$

- Escolha para N , M e G

$$N = 2^n, M = 2^k, G = 2^m$$

exemplos para N e M : 256×256 ou 512×512

exemplos para G : 256 ($m = 8$ bits/pixel) ou 4096 ($m = 12$ bits/pixel)

- Bits necessários para armazenamento

$$b = N \times M \times m \text{ bits} \quad (m = 8, N = M = 1024, \text{imagem de } 1MB)$$

Como deveria ser escolhido N , M e G ?


Compromisso:
resolução/armazenamento

Exemplo:

$G=256$,

$N=M=1024, 512, 256, 128,$
 $64, 32$

redução da resolução
espacial $\rightarrow$ efeito de xadrez
(replicação de pixels)



Exemplo:

$N=M=1024$, $G=256, 128, 64, 32, 16, 8, 4, 2$

redução dos níveis de cinza $\rightarrow$ efeito de falso contorno



(a) 256 (100%)



(b) 128 (50%)



(c) 64 (25%)



(d) 32 (12.5%)




Vizinhança

- Vizinhança de um pixel

- Vizinhança 4 (N,S,W,E pixels) $\equiv N_4(p)$. Um pixel p na coordenada (x,y) tem dois vizinhos horizontais e dois verticais:
 - $(x+1,y), (x-1,y), (x,y+1), (x,y-1)$
- Você pode adicionar os quatro vizinhos diagonais para obter o conjunto de vizinhança 8. Vizinhos diagonais $\equiv N_D(p)$.
- Vizinhança 8: inclui pixels diagonais $\equiv N_8(p)$.

Cores – RGB e Paleta

RGB -> formato baseado na tricromaticidade da visão humana, onde temos sensores para ondas curtas (azul), médias(verde) e longas(vermelho).





No modelo RGB a imagem é constituída por 3 planos ou canais, de 256 níveis de profundidade. Este modelo é denominado por true color ou 24bits pelos programas gráficos (Adobe, GIMP, etc.).

Modelo RGB

Curiosidade: o homem é capaz de discernir até 6 mil cores, o modelo RGB suporta 2^{24} , cerca de 16 milhões de cores

Problemas do Modelo RGB

- Quantidade de memória ocupada

- Nos anos 70 e 80 as placas de vídeo não eram capazes de suportar grandes volumes de memória.

- Solução, utilização de paletas de cores.

Cores segundo olho humano

Cor: combinação variável das 3 cores primárias: vermelho, verde e azul.

Padrao CIE (*Comission Internationale de l'Eclairage*):
comissão internacional de iluminação

Azul: 435.8 nm

Verde: 546.1 nm

Vermelho: 700 nm

Cores de Luz, não cores de pigmento !

Cores de Luz: adição

Cores primárias (R,G,B) são adicionadas, produzindo as cores secundárias de luz

Magenta: vermelho + azul

Cyan (turquesa): verde + azul

Amarelo: vermelho + verde

Branco:

Vermelho + verde + azul


Uma secundária + sua primária oposta !

Transformação entre espaços de cores:



$$\begin{bmatrix} X \\ Y \\ Z \end{bmatrix} = \begin{bmatrix} 0.607 & 0.173 & 0.201 \\ 0.299 & 0.587 & 0.114 \\ 0.0000 & 0.066 & 1.117 \end{bmatrix} \begin{bmatrix} R \\ G \\ B \end{bmatrix}$$

$$C = \begin{bmatrix} 0.299 & 0.587 & 0.114 \end{bmatrix} \begin{bmatrix} R \\ G \\ B \end{bmatrix}$$

Resposta



Modelo de cor HSV (Hue, Saturation, Value)



Data Augmentation Introduction

What is data augmentation?



Application of different transformation operations (rotation, flip, etc.) to the input data.

Data augmentation is an essential part of today's machine learning and deep learning applications

Makes the model more **generalizable** and serves as a natural **regularizer**

Many current data augmentation methods are derived from AutoML concept






Figure 1. Data augmentation (rotation, flip, zoom). [1]

Data Augmentation



Data Augmentation



Horizontal Flips




Data Augmentation

Random crops and scales

Training: sample random crops / scales

ResNet:

1. Pick random L in range $[256, 480]$
2. Resize training image, short side = L
3. Sample random 224×224 patch



Data Augmentation

Random crops and scales

Training: sample random crops / scales


ResNet:

1. Pick random L in range [256, 480]
2. Resize training image, short side = L
3. Sample random 224 x 224 patch

Testing: average a fixed set of crops

ResNet:

1. Resize image at 5 scales: {224, 256, 384, 480, 640}
2. For each size, use 10 224 x 224 crops: 4 corners + center, + flips



Data Augmentation

Color Jitter

Simple: Randomize
contrast and brightness



Data Augmentation

Color Jitter

Simple: Randomize
contrast and brightness



More Complex:

1. Apply PCA to all [R, G, B] pixels in training set
2. Sample a “color offset” along principal component directions
3. Add offset to all pixels of a training image

(As seen in [Krizhevsky et al. 2012], ResNet, etc)

Cutout

Training: Set random image regions to zero

Testing: Use full image

Examples:

Dropout


Data Augmentation

DropConnect

Fractional Max Pooling

Stochastic Depth

Cutout



Works very well for small datasets like CIFAR,
less common for large datasets like ImageNet

Aula 2


Domínio da Frequência e outras transformadas.

Segmentação

Extração de características

Exemplos

Pipeline convencional



<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC7218891/>